

Analisi delle Temperature sul Lago di Windermere

Progetto III per il corso di Statistica

Daniele Giaquinta

Corso di laurea in Artificial Intelligence and Data Engineering

Indice

1	Abstract	1
2	Dati	1
2.1	Osservazioni Iniziali	1
3	Decomposizione	3
4	Modelli	4
4.1	Holt-Winters	4
4.2	Yule-Walker e Minimi Quadrati	6
5	Analisi dei Residui dei Modelli	6
6	Autovalidazione	7
7	Conclusioni	8

1 Abstract

Lo scopo di questa relazione è studiare il comportamento della temperatura ambientale nell'area del Lago di Windermere nell'Inghilterra Settentrionale. I dati riportano la temperatura media mensile nella regione dal Gennaio 1946 a Dicembre 2012, fornendo quindi un arco temporale abbastanza significativo. Trovare una stagionalità annuale in questi dati risulta ovvio; sarebbe interessante scoprire tuttavia se in tutti questi anni si nota anche un trend particolare.

2 Dati

Il dataset è reperibile al link <https://catalogue.ceh.ac.uk/documents/453fdf49-7328-42ec-94b7-1cebf06c51e2> previa creazione di un account gratuito.

2.1 Osservazioni Iniziali

Dall'osservazione della serie ci si accorge subito di trovarci davanti ad una serie dominata da stagionalità ed era anche facile aspettarselo [Figura 1](#). Le funzioni di

autocorrelazioni al netto del trend e non (simili essendo la serie predominata da stagionalità) confermano la stagionalità annuale con i picchi positivi in ogni periodo [Figura 2](#). Dal grafico di quest'ultima è interessante notare come le temperature più basse corrispondano agli anni più lontani [Figura 3](#). Ovviamente questo non è osservabile dal grafico della stagionalità normalizzata, che per il resto è molto simile suggerendo una stagionalità uniforme e quindi è omesso.




Figura 1: Visione della serie




Figura 2: Funzioni di autocorrelazione con trend e al netto del trend




Figura 3: Stagionalità NON normalizzata e bande di confidenza

3 Decomposizione

Per quanto riguarda la decomposizione [Figura 4](#) [Figura 5](#), il modello scelto è quello additivo standard; tra i due modelli additivi è infatti quello che ottiene risultati migliori sia dal punto di vista della struttura conservata dai residui [Figura 7](#) che della normalità di questi ultimi.




Figura 4: Decomposizione additiva (sinistra) e moltiplicativa (destra)

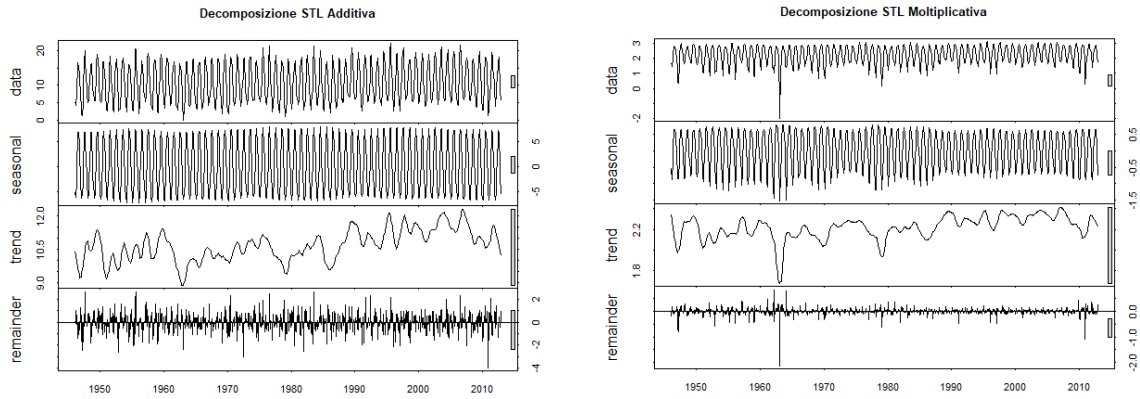


Figura 5: Decomposizione STL additiva (sinistra) e STL moltiplicativa (destra)

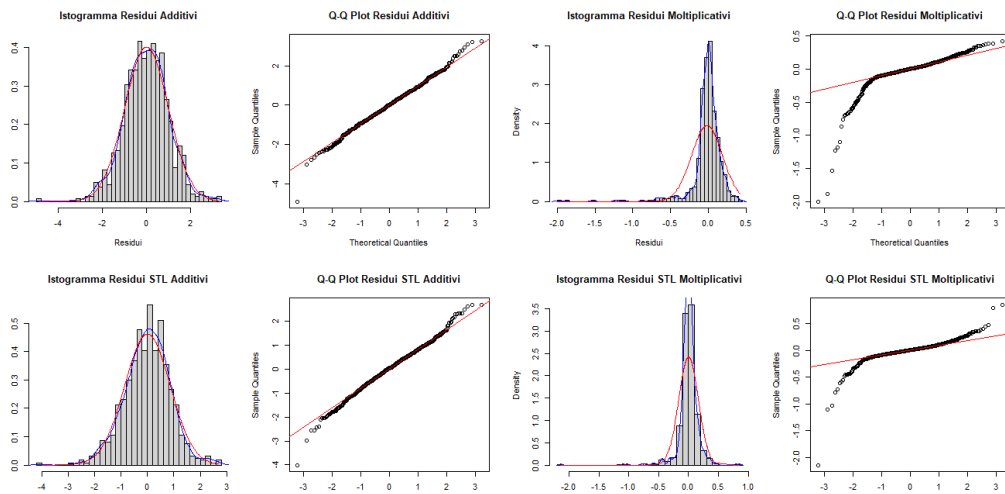


Figura 6: Analisi dei residui delle decomposizioni

I modelli moltiplicativi sebbene sembrano avere residui che conservano meno struttura nei lag più avanzati, presentano dei lag iniziali troppo anomali e i residui sono molto più lontani dalla normalità [Figura 6](#) . In conclusione siamo quindi nell'ipotesi di una stagionalità uniforme.

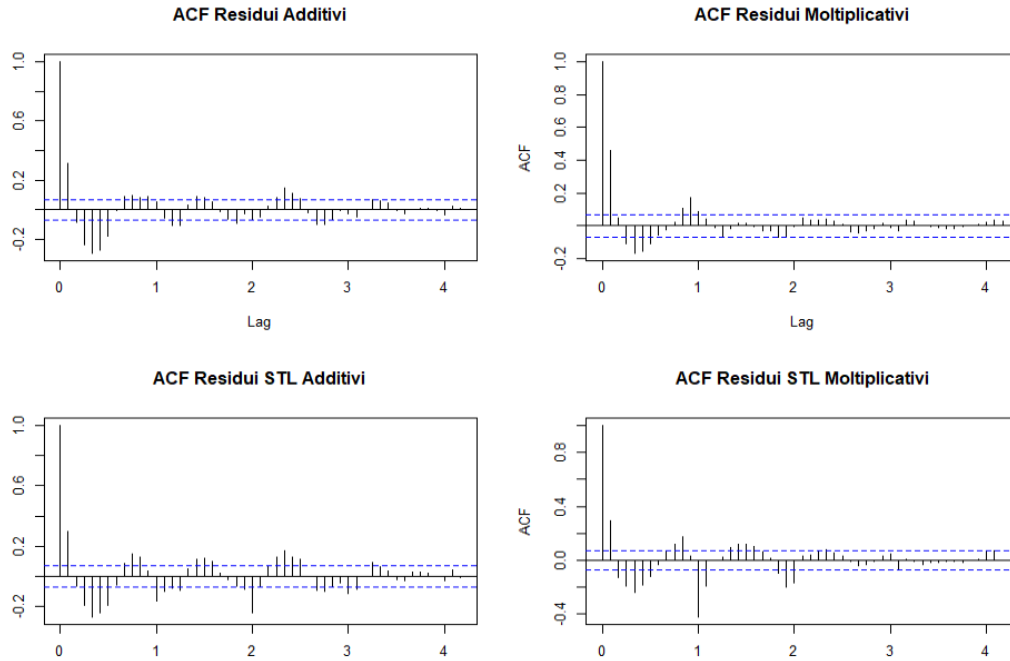


Figura 7: Funzione di autocorrelazione dei residui delle decomposizioni

Le deviazioni standard delle funzioni di autocorrelazione vedono in vantaggio il modello moltiplicativo ma questo risulta comunque poco convincente; tra i due additivi il migliore risulta ancora quello standard:

	sd
add	0.229247
mul	0.2169215
add STL	0.2319557
mul STL	0.2380088

4 Modelli

Si è tentato l'utilizzo di modelli che sfruttano il metodo di Holt-Winters con parametri automatici e manuali e due metodi autoregressivi; Yule-Walker e Minimi Quadrati.

4.1 Holt-Winters

Il modello di Holt-Winters automatico ha settato i parametri $\alpha=0.317$, $\beta=0.004$, $\gamma=0.232$. Ha difficoltà a seguire il trend ma a meno di qualche imprecisione sui

picchi segue molto bene la stagionalità; in [Figura 8](#) è rappresentata una finestra temporale ristretta per leggibilità.




Figura 8: Confronto tra Holt-Winters automatico e modello additivo

Un modello con parametri settati manualmente è stato creato ricavando le condizioni iniziali tramite regressione lineare per tentare di inseguire meglio il trend. I parametri scelti sono $\alpha=0.3$, $\beta=0.1$, $\gamma=0.2$. Il risultato [Figura 9](#) sembra leggermente più convincente poiché il trend è più centrato e c'è meno differenza nei picchi di stagionalità.




Figura 9: Confronto tra Holt-Winters manuale e modello additivo

Infine è mostrata la previsione per i due modelli e gli intervalli di confidenza non parametrici. I due risultati sono molto simili [Figura 10](#), si nota una leggera riduzione degli intervalli nel modello con parametri manuali; i modelli saranno confrontati più a fondo in seguito tramite i residui.

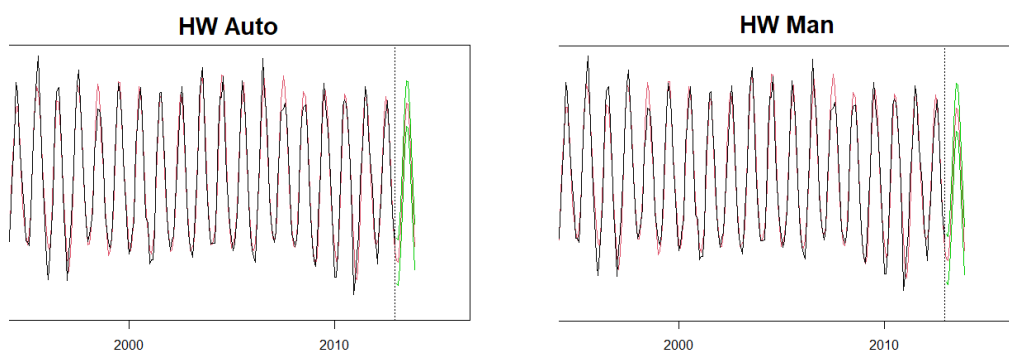


Figura 10: Confronto tra Holt-Winters automatico e manuale in previsione

4.2 Yule-Walker e Minimi Quadrati

Anche con i modelli autoregressivi le previsioni risultano indistinguibili da quelle ottenute con i modelli di Holt-Winters [Figura 11](#), ci si servirà quindi dell'analisi dei residui e dell'autovalidazione per stabilire il modello migliore.

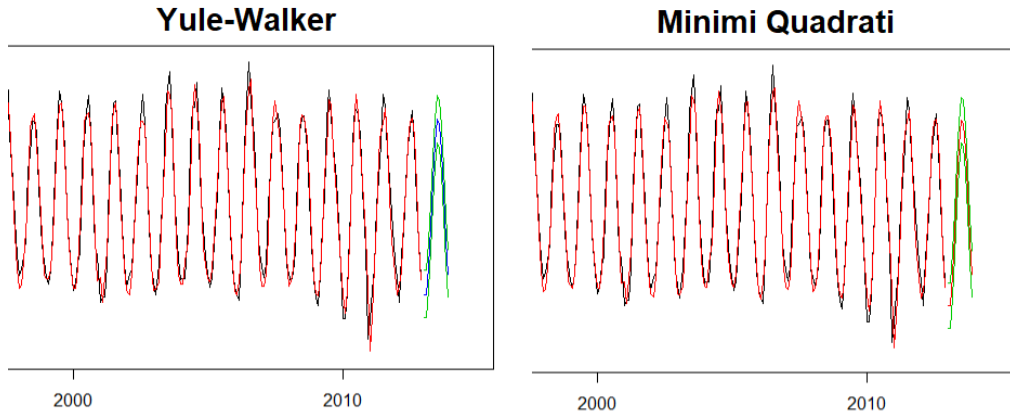


Figura 11: Confronto tra Yule-Walker e Minimi Quadrati in previsione

5 Analisi dei Residui dei Modelli

Le analisi dei residui non restituiscono risultati proprio uguali per tutti i modelli [Figura 12](#), infatti il modello di Holt-Winter con parametri automatici produce i residui peggiori, dove con peggiore si intende meno Gaussiani. Il modello di Holt-Winter con parametri manuali migliora leggermente, ottenendo 0.015 allo Shapiro-Wilk test segnando quasi un superamento della soglia. I modelli autoregressivi invece superano entrambi ampiamente lo Shapiro test.

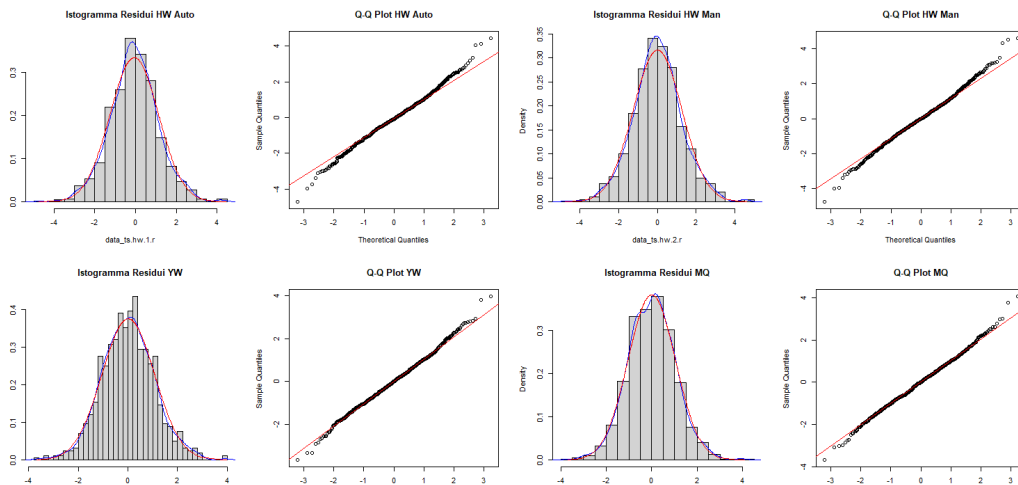


Figura 12: Analisi dei residui dei modelli

Dalle funzioni di autocorrelazione dei residui [Figura 13](#) si nota ancora una volta che i modelli autoregressivi sono migliori, conservando meno struttura nei residui. Tra questi due il modello migliore sembra essere quello dei Minimi Quadrati

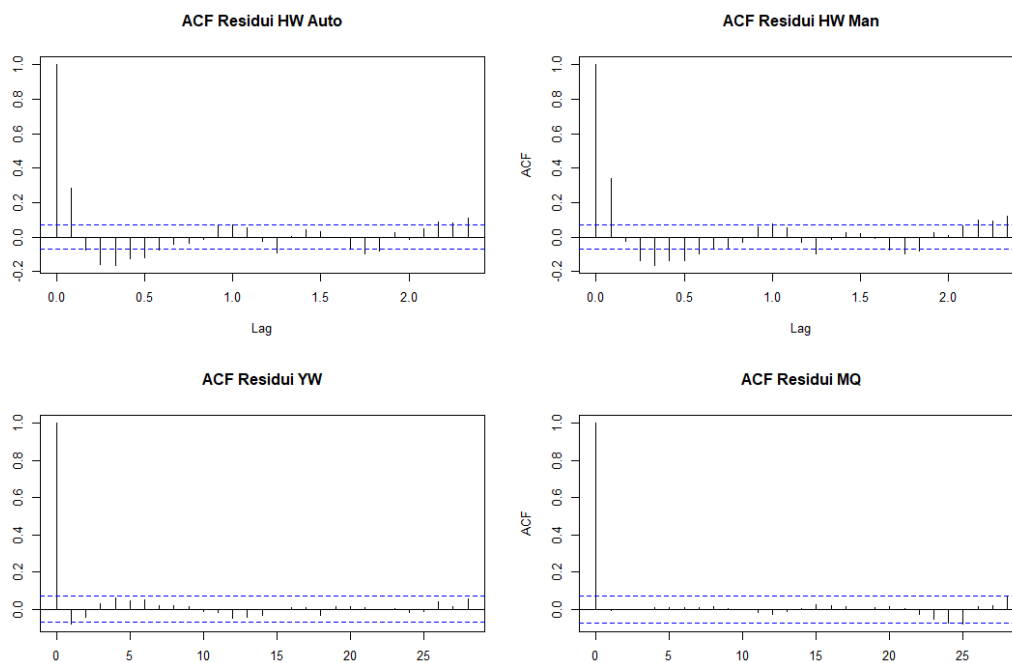


Figura 13: Funzioni di autocorrelazione dei residui dei modelli

6 Autovalidazione

L'ultimo parametro di giudizio per la scelta del modello è l'autovalidazione sull'ultimo anno della serie [Figura 14](#), ovvero il 2012, con cui si sono ottenuti gli errori medi nella tabella sottostante; il modello migliore si conferma quello dei minimi quadrati.




Figura 14: Autovalidazione sull'ultimo anno della serie

	Errore Medio
HW Auto	1.022341
HW Man	1.030423
YW	0.7983478
LS	0.7924036

7 Conclusioni

In epilogo il metodo dei Minimi Quadrati risulta avere residui più Gaussiani e ha un errore medio inferiore a quello degli altri modelli, pertanto non c'è dubbio sulla sua scelta. Viene dunque utilizzato per effettuare la previsione del primo anno fuori range, il 2013 [Figura 15](#). Si mostrano minime previste di circa 3 gradi e massime di circa 17, con bande di confidenza di 1 grado ad aumentare o diminuire.




Figura 15: Previsione del 2013 col modello dei Minimi Quadrati

Appendice

Codice R

```
library(readr)
data <- read_csv("tabella.csv")

# Conversione dei due attributi anno e mese in un unico
  attributo di tipo date
month.names <- c("Jan", "Feb", "Mar", "Apr", "May", "Jun", "
  Jul", "Aug", "Sep", "Oct", "Nov", "Dec")
data$Month <- match(data$Month, month.names)
data$date <- as.Date(paste(data$Year, data$Month, 1), format =
  "%Y %m %d")
data <- data[, -c(1, 2)]
data <- data[, c("date", "Temp")]

View(data)
head(data)
summary(data)

# Costruzione Time Series
data_ts <- ts(data$Temp, frequency = 12, start = 1946, end = c
  (2012, 12))
head(data_ts)
ts.plot(data_ts, xlab="Anni", ylab="Temp (in gradi Celsius)")

# Parametri Time Series
start(data_ts)
end(data_ts)
frequency(data_ts)

# ACF
layout(matrix(1:2,1,2))
acf(data_ts, 25)
acf(diff(data_ts), 25)
layout(1)

layout(matrix(1:2,1,2))
# Confronto Stagionalità
m_data = matrix(data_ts, 12, 67)
ts.plot(m_data, col = heat.colors(67), main = "Confronto
  Stagionalità ", ylab = "Temp (in gradi Celsius)", lwd=2)
lines(rowMeans(m_data),lwd=3,col="blue")

# Rimuoviamo il trend normalizzando
```

```

ts.plot(scale(m_data, scale=F), col = heat.colors(67), main =
  "Confronto Stagionalit ", ylab = "Temp Normalizzate", xlab
  ="Mese", lwd=1.5)
par(bg = "white")

# Bande di confidenza Stagionalit
data_ts.sd=vector("numeric",12)
for(i in 1:12){
  data_ts.sd[i]=sd(m_data[i,])
}

layout(1)
data_ts.m=rowMeans(m_data)
plot(data_ts.m,pch=20,type="b", ylim=range(c(data_ts.m-3*data_
  ts.sd, data_ts.m+3*data_ts.sd)),
  main = "Bande di Confidenza della Stagionalit ", ylab="
  Temp (in gradi Celsius)", xlab="Mese")
arrows(1:12,data_ts.m-data_ts.sd,1:12,data_ts.m+data_ts.sd,
  length=0.02,angle=90,
  code=3,col="green3")
points(data_ts.m+data_ts.sd,type="b",pch=20,col="gray")
points(data_ts.m-data_ts.sd,type="b",pch=20,col="gray")

# Boxplot Stagionalit
boxplot(t(m_data), pch=19)
boxplot(t(scale(m_data, scale=F)), pch=19)

# DECOMPOSIZIONE

# Decomposizione Additiva
data_ts.da=decompose(data_ts)
plot(data_ts.da)
# Decomposizione Moltiplicativa
data_ts.dm=decompose(data_ts, type="multiplicative")
plot(data_ts.dm)
# Stl Additivo
data_ts.stla = stl(data_ts,s.window=11)
plot(data_ts.stla, main="Decomposizione STL Additiva")
# per l'Stl Moltiplicativo va rimosso un -inf che compare per
  una temperatura media di 0 gradi dopo il logaritmo
logdata=log(data_ts)
logdata[206]=-2
# Stl Moltiplicativo
data_ts.stlm = stl(logdata,s.window=7)
plot(data_ts.stlm, main="Decomposizione STL Moltiplicativa")

# Confronto Stagionalit

```

```

plot(data_ts.da$seasonal, main = "Confronto Stagionalit ",
     ylab = "Stagionalit ")
lines(mean(data_ts.dm$trend, na.rm=T)*(data_ts.dm$seasonal-1),
      col="red")
lines(data_ts.stla$time.series[,1], col="green")
lines(data_ts.stlm$time.series[,1]*mean(data_ts.stla$time.
     series[,2], na.rm=T), col="blue")
# Confronto rumore
plot(data_ts.da$random, ylab="Rumore")
lines(mean(data_ts.dm$trend, na.rm=TRUE)*(data_ts.dm$random-1),
      col="red")
lines(data_ts.stla$time.series[,3], col="green")
lines(data_ts.stlm$time.series[,3]*mean(data_ts.stla$time.
     series[,2], na.rm=T), col="blue")

```

ANALISI DEI RESIDUI

DECOMPOSIZIONE ADDITIVA

```

data_ts.dar <- na.omit(data_ts.da$random)
layout(matrix(1:8, 2, 4, byrow = TRUE))
# Istogramma
hist(data_ts.dar, 35, freq=F, main="Istogramma Residui
     Additivi", xlab="Residui")
lines(density(data_ts.dar), col="blue")
lines(sort(data_ts.dar), dnorm(sort(data_ts.dar), mean(data_ts
     .dar), sd(data_ts.dar)), col="red")

```

Q-Q Plot

```

qqnorm(data_ts.dar, main="Q-Q Plot Residui Additivi")
qqline(data_ts.dar, col="red")

```

Shapiro Wilk

```

shapiro.test(data_ts.dar)

```

DECOMPOSIZIONE MOLTIPLICATIVA

```

data_ts.dmr <- na.omit(log(data_ts.dm$random))
data_ts.dmr[200]=-2

```

Istogramma

```

hist(data_ts.dmr, 35, freq=F, main="Istogramma Residui
     Moltiplicativi", xlab="Residui")
lines(density(data_ts.dmr), col="blue")
lines(sort(data_ts.dmr), dnorm(sort(data_ts.dmr), mean(data_ts
     .dmr), sd(data_ts.dmr)), col="red")

```

Q-Q Plot

```

qqnorm(data_ts.dmr, main="Q-Q Plot Residui Moltiplicativi")
qqline(data_ts.dmr, col="red")

```

Shapiro Wilk

```

shapiro.test(data_ts.dmr)

```

DECOMPOSIZIONE STL ADDITIVA

```

data_ts.stlar <- data_ts.stla$time.series[,3]

```

Istogramma

```

hist(data_ts.stlar, 30, freq=F, main="Istogramma Residui STL
     Additivi", xlab="Residui")
lines(density(data_ts.stlar), col="blue")

```

```

lines(sort(data_ts.stlar), dnorm(sort(data_ts.stlar), mean(
  data_ts.stlar), sd(data_ts.stlar)), col="red")
# Q-Q Plot
qqnorm(data_ts.stlar, main="Q-Q Plot Residui STL Additivi")
qqline(data_ts.stlar, col="red")
# Shapiro Wilk
shapiro.test(data_ts.stlar)
# DECOMPOSIZIONE STL MOLTIPLICATIVA
data_ts.stlmr <- data_ts.stlm$time.series[,3]
# Istogramma
hist(data_ts.stlmr, 40, freq=F, main="Istogramma Residui STL
  Moltiplicativi", xlab="Residui")
lines(density(data_ts.stlmr), col="blue")
lines(sort(data_ts.stlmr), dnorm(sort(data_ts.stlmr), mean(
  data_ts.stlmr), sd(data_ts.stlmr)), col="red")
# Q-Q Plot
qqnorm(data_ts.stlmr, main="Q-Q Plot Residui STL
  Moltiplicativi")
qqline(data_ts.stlmr, col="red")
# Shapiro Wilk
shapiro.test(data_ts.stlmr)

layout(matrix(c(1,2,3,4), 2, 2, byrow = TRUE))
# ACF Residui
acf(data_ts.dar, 50, main = "ACF Residui Additivi")
# ACF Residui
acf(data_ts.dmr, 50, main = "ACF Residui Moltiplicativi")
# ACF Residui
acf(data_ts.stlar, 50, main = "ACF Residui STL Additivi")
# ACF Residui
acf(data_ts.stlmr, 50, main = "ACF Residui STL Moltiplicativi"
  )

# Confronto Deviazione Standard modelli di Decomposizione
sd(acf(data_ts.dar, plot=F)$acf)
sd(acf(data_ts.dmr, plot=F)$acf)
sd(acf(data_ts.stlar, plot = F)$acf)
sd(acf(data_ts.stlmr, plot = F)$acf)

# Holt Winters
layout(1)
data_ts.hw.1 = HoltWinters(data_ts)
plot(data_ts.hw.1)

data_ts.hw.1$alpha
data_ts.hw.1$beta
data_ts.hw.1$gamma

```

```

# Confronto con additivo
layout(matrix(1:2,1,2))
# Trend
ts.plot(window(data_ts.da$trend, c(1990, 1)),window(data_ts.hw
.1$fitted[,2], c(1990, 1)),col=c("black","red"), main = "
Confronto HW Auto con Trend Dec.Additiva")
legend(
  "bottomleft",
  legend = c( "Additivo", "Holt-Winters Auto"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)
# Stagionalit
ts.plot(window(data_ts.da$seasonal, c(1990, 1)),window(data_ts
.hw.1$fitted[,4], c(1990, 1)),col=c("black","red"), main =
"Confronto HW Auto con Stagionalit Dec.Additiva")
legend(
  "bottomleft",
  legend = c( "Additivo", "Holt-Winters Auto"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)

```

```

# Holt Winters Manuale
x=1:20
# intercept al posto di l.start e x al posto di b.start
coefficients(lm(data_ts[1:20]~x))
data_ts.hw.2 = HoltWinters(data_ts, alpha=0.3, beta=0.1, gamma
=0.2, l.start=6.8927895, b.start=-0.2570677)
layout(1)
plot(data_ts.hw.2)
plot(data_ts.hw.2$fitted)
# Confronto con decomposizione additiva
layout(matrix(1:2,1,2))
# Trend
ts.plot(window(data_ts.da$trend, c(1990, 1)),window(data_ts.hw
.2$fitted[,2], c(1990, 1)),col=c("black","red"), main = "
Confronto HW Man con Trend Dec.Additiva")
legend(
  "bottomleft",
  legend = c( "Additivo", "Holt-Winters Man"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)
# Stagionalit
ts.plot(window(data_ts.da$seasonal, c(1990, 1)),window(data_ts
.hw.2$fitted[,4], c(1990, 1)),col=c("black","red"), main =

```

```

    "Confronto HW Man con Stagionalit Dec.Additiva")
legend(
  "bottomleft",
  legend = c( "Additivo", "Holt-Winters Man"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)
layout(1)

# Autoregressione con Yule-Walker
data_ts.ar = ar(data_ts)
data_ts.ar
data_ts.ar$var/var(data_ts[15:length(data_ts)])

data_ts.ar.an = data_ts - data_ts.ar$resid

# Autoregressione con Minimi Quadrati
data_ts.ls = ar(data_ts, method="ols")
data_ts.ls
data_ts.ar$var/var(data_ts[23:length(data_ts)])

data_ts.ls.an = data_ts - data_ts.ls$resid

# ANALISI DEI RESIDUI
# Holt Winters con parametri automatici
data_ts.hw.1.r = residuals(data_ts.hw.1)
plot(data_ts.hw.1.r, type="p", pch=20)
# Varianza (non) Spiegata
var(data_ts.hw.1.r)/var(window(data_ts, c(2001, 1)))

# Incertezza
plot(data_ts.hw.1, predict(data_ts.hw.1, 12), main="Holt -
  Winters Auto")
lines(predict(data_ts.hw.1, 12) + quantile(data_ts.hw.1.r,
  0.05), col="green3")
lines(predict(data_ts.hw.1, 12) + quantile(data_ts.hw.1.r,
  0.95), col="green3")
legend(
  "bottomleft",
  legend = c( "Osservazioni", "Holt-Winters Auto"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)

# Holt Winters con parametri manuali

```

```

data_ts.hw.2.r = residuals(data_ts.hw.2)
plot(data_ts.hw.2.r, type="p", pch=20)
plot(data_ts.hw.2$fitted[,1], data_ts.hw.2.r, pch=20)
# Varianza Spiegata
var(data_ts.hw.2.r)/var(window(data_ts, c(2001, 1)))

# Incertezza
plot(data_ts.hw.2, predict(data_ts.hw.2, 12), main="Holt -
  Winters Manuale")
lines(predict(data_ts.hw.2, 12) + quantile(data_ts.hw.2.r,
  0.05), col="green3")
lines(predict(data_ts.hw.2, 12) + quantile(data_ts.hw.2.r,
  0.95), col="green3")
legend(
  "bottomleft",
  legend = c( "Osservazioni", "Holt-Winters Manuale"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)

# Yule Walker
data_ts.ar.r = data_ts.ar$resid[24:804]
plot(data_ts.ar.r, type="p", pch=20)

# Incertezza
data_ts.ar.pt = predict(data_ts.ar, n.ahead = 12, se.fit =
  FALSE)
plot(data_ts, main = "Yule-Walker", col="black")
lines(data_ts.ar.pt, col = "blue")
lines(data_ts - data_ts.ar$resid, col = "red")
lines(data_ts.ar.pt + quantile(data_ts.ar.r, 0.05), col="
  green3")
lines(data_ts.ar.pt + quantile(data_ts.ar.r, 0.95), col="
  green3")
legend(
  "bottomleft",
  legend = c( "Osservazioni", "Yule-Walker"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)

# Minimi Quadrati
data_ts.ls.r = data_ts.ls$resid[26:804]
plot(data_ts.ls.r, type="p", pch=20)

# Incertezza
data_ts.ls.pt = predict(data_ts.ls, n.ahead = 12, se.fit =
  FALSE)
plot(data_ts, main = "Minimi Quadrati", col="black")
lines(data_ts.ls.pt, col = "red")

```

```

lines(data_ts -data_ts.ls$resid, col = "red")
lines(data_ts.ls.pt + quantile(data_ts.ls.r, 0.05), col="
  green3")
lines(data_ts.ls.pt + quantile(data_ts.ls.r, 0.95), col="
  green3")
legend(
  "bottomleft",
  legend = c( "Osservazioni", "Minimi Quadrati"),
  col = c("black", "red"),
  lwd = 2,
  cex = 0.6
)

layout(matrix(1:8, 2, 4, byrow = TRUE))
# Istogramma
hist(data_ts.hw.1.r, 30, freq=F, main="Istogramma Residui HW
  Auto")
lines(density(data_ts.hw.1.r),col="blue")
lines(sort(na.omit(data_ts.hw.1.r)),dnorm(sort(na.omit(data_ts
  .hw.1.r)),mean(na.omit(data_ts.hw.1.r)),sd(na.omit(data_ts.
  hw.1.r)))),col="red")
# Q-Q Plot
qqnorm(data_ts.hw.1.r,main = "Q-Q Plot HW Auto")
qqline(data_ts.hw.1.r, col="red")
# Shapiro Test
shapiro.test(data_ts.hw.1.r)

# Istogramma
hist(data_ts.hw.2.r, 30, freq=F, main="Istogramma Residui HW
  Man")
lines(density(data_ts.hw.2.r),col="blue")
lines(sort(na.omit(data_ts.hw.2.r)),dnorm(sort(na.omit(data_ts
  .hw.2.r)),mean(na.omit(data_ts.hw.2.r)),sd(na.omit(data_ts.
  hw.2.r)))),col="red")
# Q-Q Plot
qqnorm(data_ts.hw.2.r,main = "Q-Q Plot HW Man")
qqline(data_ts.hw.2.r, col="red")
# Shapiro Test
shapiro.test(data_ts.hw.2.r)

# Istogramma
hist(data_ts.ar.r, 30, freq=F, main="Istogramma Residui YW")
lines(density(data_ts.ar.r),col="blue")
lines(sort(na.omit(data_ts.ar.r)),dnorm(sort(na.omit(data_ts.
  ar.r)),mean(na.omit(data_ts.ar.r)),sd(na.omit(data_ts.ar.r)
  )),col="red")
# Q-Q Plot
qqnorm(data_ts.ar.r,main = "Q-Q Plot YW")
qqline(data_ts.ar.r, col="red")
# Shapiro Test
shapiro.test(data_ts.ar.r)

```



```

# Istogramma
hist(data_ts.ls.r, 20, freq=F, main="Istogramma Residui MQ")
lines(density(data_ts.ls.r), col="blue")
lines(sort(na.omit(data_ts.ls.r)), dnorm(sort(na.omit(data_ts.
  ls.r)), mean(na.omit(data_ts.ls.r)), sd(na.omit(data_ts.ls.r)
  )), col="red")
# Q-Q Plot
qqnorm(data_ts.ls.r, main = "Q-Q Plot MQ")
qqline(data_ts.ls.r, col="red")
# Shapiro Test
shapiro.test(data_ts.ls.r)

layout(matrix(c(1,2,3,4), 2, 2, byrow = TRUE))
# Autocorrelazione
acf(data_ts.hw.1.r, main="ACF Residui HW Auto")
# Autocorrelazione
acf(data_ts.hw.2.r, main="ACF Residui HW Man")
# Autocorrelazione
acf(data_ts.ar.r, main="ACF Residui YW")
# Autocorrelazione
acf(data_ts.ls.r, main="ACF Residui MQ")

# AUTOVALIDAZIONE
layout(1)
# Previsione 2012
res.hw.1 = rep(0,11)
res.hw.2 = rep(0,11)
res.ar = rep(0,11)
res.ls = rep(0,11)

for (i in 1:11) {
  train = window(data_ts, end = c(2012, i))
  test = window(data_ts, start = c(2012, i+1))
  res.hw.1[i] = predict(HoltWinters(train, alpha = 0.3167558 ,
    beta = 0.003596265, gamma = 0.2323031), 1) #automatico
  res.hw.2[i] = predict(HoltWinters(train, alpha=0.30, beta=
    FALSE, gamma=0.25, l.start=6.8927895, b.start=-0.2570677),
    1) #manuale
  res.ar[i] = predict(ar(train), n.ahead = 1, se.fit = F) #yw
  res.ls[i] = predict(ar(train, method="ols"), n.ahead = 1, se
    .fit = F) #minquad
}

test = window(data_ts, start=c(2012, 2))
sqrt(mean((test-res.hw.1)^2))
sqrt(mean((test-res.hw.2)^2))
sqrt(mean((test-res.ar)^2))
sqrt(mean((test-res.ls)^2))

```

```

ts.plot(test, res.hw.1, res.hw.2, res.ar, res.ls, main="
  Confronto 2012", col=c("black", "blue", "red", "green3", "
    yellow"))
legend(
  "bottom",
  legend = c( "Test", "HW Auto", "HW Man", "YW", "MQ"),
  col = c("black", "blue", "red", "green3", "yellow"),
  lwd = 2,
  cex = 0.6
)

```

```

# Previsione Minimi Quadrati, modello scelto
data_ts.ls.pt = predict(data_ts.ls, n.ahead=12, se.fit=FALSE)
data_ts.ls.r = data_ts.ls$resid[26:804]

y.max = max(data_ts.ls.pt + quantile(data_ts.ls.r, 0.95))
y.min = min(data_ts.ls.pt + quantile(data_ts.ls.r, 0.05))
ts.plot(data_ts.ls.pt, ylim=c(y.min, y.max), col="red", main="
  Previsione Finale")
lines(data_ts.ls.pt + quantile(data_ts.ls.r, 0.95), col = "
  green3")
lines(data_ts.ls.pt + quantile(data_ts.ls.r, 0.05), col = "
  green3")

```